

Тестовое задание для Python-разработчика направления Data Engineering

Формат сдачи:

Оформите итоговое решение в виде одного Git-репозитория с двумя папками:

- `task1` - анализ и модификация XML-аннотаций
- `task2` - обработка COCO-датасета

Каждое задание оформляется в виде отдельных `.py` файлов. Добавьте обязательный `README.md` с инструкциями по запуску, описанием зависимостей и форматом выходных файлов.

1. Задание по разметке: анализ XML-аннотаций

Описание:

Работа с XML-файлами аннотаций. Цель - извлечь и обработать статистику по изображениям, классам и фигурам, а также внести правки в данные.

Входные файлы:

- `annotations.xml`
- `annotations-2.xml`
- `annotations-3.xml`

Основные понятия:

- **Изображение** - элемент `image` в XML
- **Фигура** - элемент типа `box`, `polygon` или `points`
- **Класс** - атрибут `label` у фигуры, например `ignore`, `fur`, `item`

Решение должно быть представлено в виде трех обязательных скриптов и одного опционального скрипта:

Скрипт 1: Общая статистика

Обрабатывает все XML-файлы и выводит:

1. Общее количество изображений
2. Количество размеченных изображений, где есть хотя бы одна фигура
3. Количество неразмеченных изображений
4. Количество всех фигур в сумме по всем изображениям
5. Размер (ширина, высота) и название самого большого и самого маленького изображения. Если таких изображений несколько, вывести их количество и параметры любого одного из них.

Скрипт 2: Статистика по классам

Обрабатывает все XML-файлы и выводит список всех уникальных классов и количество фигур каждого класса, например:

```
ignore: 300  
fur: 120  
item: 45
```

Скрипт 3*: Статистика по типам фигур (опционально)

Обрабатывает все XML-файлы и выводит количество фигур по типам (`box`, `polygon`, `points`), независимо от класса:

```
box: 234  
polygon: 1056  
points: 74
```

Скрипт 4: Модификация XML-файлов

Изменения в каждом XML:

1. Перевернуть порядок `id` у изображений - присвоить им обратные значения, например от последнего к первому.
2. Изменить `name` у изображений: удалить путь, оставить только имя файла; заменить расширение на `.png`.

Скрипт должен сохранять измененные копии файлов с суффиксом `_modified`, не перезаписывая исходные XML.

2. Работа с COCO-датасетом

Входные данные:

Вам предоставлен архив `task_train_coco 1.0.zip`, содержащий:

- Файлы изображений
- Файл аннотаций в формате COCO (JSON)

Цель задания:

1. Проанализировать датасет COCO
2. Перестроить структуру изображений на диске согласно классам
3. Обновить пути в аннотациях
4. Проверить корректность обновленного датасета и сформировать краткий отчет
5. Опционально преобразовать датасет в формат YOLO

Решение должно быть представлено в виде двух обязательных скриптов и одного опционального скрипта:

Скрипт 1: Реструктуризация датасета

Цель:

Изменить структуру изображений в соответствии с классами из аннотаций.

Описание задачи:

- Для каждого изображения определить классы объектов, присутствующих на нем.
- Изображение должно быть перемещено в директорию `images/<имя_класса>/`. Если в изображении больше одного класса, создать папку с именем, объединяющим все классы через `_`.
- Обновить пути к изображениям в COCO-аннотации так, чтобы поле `file_name` соответствовало новой структуре.

Примеры:

```
playhood_5 -> images/playhood/  
something_1 -> images/something/  
car_3, dog_1 -> images/car_dog/
```

Вывод:

- Обновленная структура папок с изображениями
- Обновленный файл аннотаций `updated_annotations.json`

Скрипт 2: Валидация и отчет по датасету

Цель:

Проверить, что реструктурированный датасет и обновленная COCO-аннотация согласованы между собой.

Требования:

- Проверить, что каждый путь из `file_name` существует на диске.
- Проверить, что все `image_id` из аннотаций есть в списке изображений.
- Проверить, что все `category_id` из аннотаций есть в списке категорий.
- Вывести количество изображений, аннотаций, категорий, пустых изображений и найденных ошибок.
- Сохранить отчет в файл `dataset_report.json` или `dataset_report.md`.

Скрипт 3*: Преобразование в формат YOLO (опционально)

Цель:

Преобразовать аннотации из COCO в YOLO.

Условия:

- Используйте структуру директорий, сформированную в скрипте 1.
- YOLO-аннотации должны быть сохранены в виде `.txt` файлов с тем же именем, что и изображение.

Структура для YOLO:

```
yolo_dataset/  
  class1/  
    image1.jpg  
    image1.txt  
  class1_class2/  
    image2.jpg  
    image2.txt
```

YOLO формат:

```
<class_id> <x_center> <y_center> <width> <height>
```

Координаты должны быть нормализованы в диапазоне [0, 1].

Если все понятно - удачи в выполнении задания. Если есть вопросы, не стесняйтесь задать их.